ACT 2.1

<u>Investigacion sobre que es un sistema RAG (Retrieval Augmented Generation)</u>

1- Para empezar estoy buscando información sobre que es y como crearlo en la IA NotebookLM

2-Una vez he entendido en que consiste un sistema RAG le he proporcionado el siguiente prompt a Antigravity:

1. Actúa como Arquitecto Senior de IA. Diseña un sistema RAG modular con FastAPI (Backend) y React (Frontend).
2. Implementa un pipeline de ingesta con chunking (500-1000 tokens) y embeddings usando el modelo e5-large-v2.
3. Usa FAISS como base vectorial y PostgreSQL para gestionar metadatos, chats y documentos originales.
4. El flujo de consulta debe incluir recuperación k-NN seguida de una etapa de reranking con Cross-Encoder.
5. Para la generación, integra el LLM Nous-Hermes-2 vía Ollama para asegurar ejecución local y privacidad.
6. Cada respuesta debe ser trazable, citando explícitamente los fragmentos documentales utilizados como fuente.
7. Evalúa la calidad del sistema mediante el framework RAGAS (relevancia, fidelidad factual y cobertura).
8. Entrega el diseño de microservicios en Docker, el esquema relacional y el código base del pipeline

3-He conseguido que me cree el sistema RAG funcional, al final le he adjuntado este ultimo prompt para que subiera el sistema ademas de un reedme y una pagina web explicativa y funcional

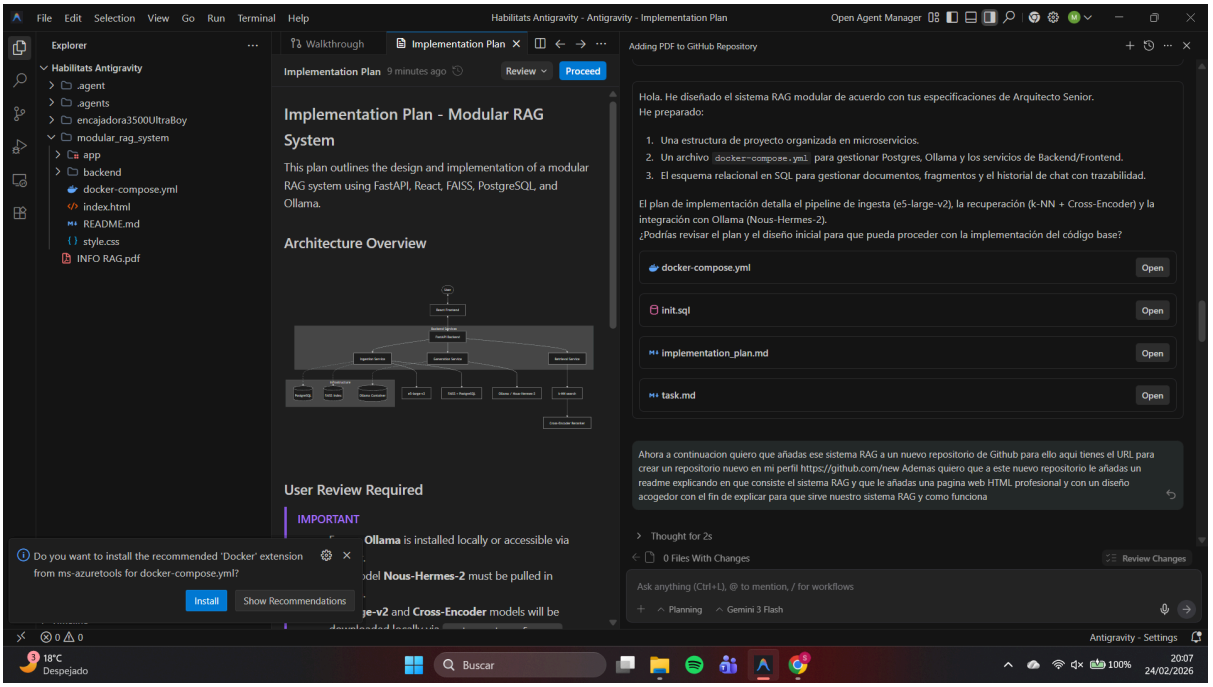

Asi termina la primera parte de la ACT2